PRÁCTICA III:

...

Implementación de un Sistema de Recuperación de Información utilizando Lucene

...

Indexación

21 de octubre de 2021

Índice

1. Objetivo

El objetivo final de esta práctica es que el alumno comprenda todos los procesos que intervienen en el diseño de un Sistema de Recuperación de Información y cómo puede ser implementado utilizando la biblioteca Lucene. Para ello, en este curso utilizaremos la base de datos CORD-19, vista en la práctica anterior. Nuestro objetivo será construir un programa que se pueda ejecutar en línea de comandos y que sea el encargado de generar/actualizar nuestro índice.

Esta tarea forma parte de la práctica final, la cual ha sido dividida en tres grandes bloques, haciendo referencia esta documentación a la segunda de ellas. En las siguientes semanas se entregará la documentación relativa a las otras partes, relacionadas con búsqueda y uso de facetas.

Esta práctica representa el primer paso hacia la práctica final de la asignatura (que en su totalidad es un 80 % de la nota final de prácticas). La práctica final se dividirá en 3 bloques en total, que se irán entregando conforme avance la asignatura.

En cualquier aplicación de búsqueda podemos distinguir los siguientes pasos, que detallaremos a continuación:

1. Análisis de requisitos y adquisición de datos.
2. Procesamiento de los datos, que ya hemos considerado en parte en prácticas anteriores.
3. Indexación y almacenamiento de los mismos.
4. Búsqueda sobre el índice y presentación de los resultados.

2. Diseñando el Sistema de Recuperación de Información

A la hora de diseñar cualquier aplicación de búsqueda, el primer paso es analizar qué tipo de información se va a buscar y cómo se realizan las búsquedas por parte de un usuario. En esta práctica el objetivo es crear un buscador sobre un conjunto de datos artículos científicos sobre distintas temáticas.

La colección de datos en este caso la podremos crear a partir de consultas a la base de datos bibliográfica Scopus https://www.scopus.com. Scopus contiene información sobre artículos publicados en unas numerosos medios (revistas, congresos, ...) científicos. Aunque Scopus tiene más información de la que utilizaremos en la práctica, en este caso nos centraremos en datos que podremos descargar desde la interfaz pública de la misma.

En la práctica consideraremos dos tipos de información:

- Citation Information: Donde se incluye los autores, el título del trabajo, año de publicación, fuente donde se publicó, citas, etc.
- Abstract y Keywords: Que contiene un breve resumen del trabajo, palabras claves dadas por los autores y las utilizadas para indexar.

Un ejemplo (en formato bibtex) de lo que podemos descarganos es:

```
1
2  @ARTICLE{Lima2022,
3  author={Lima, H.B. and Santos, C.G.R.D. and Meiguins, B.S.},
4  title={A Survey of Music Visualization Techniques},
5  journal={ACM Computing Surveys},
6  year={2022},
7  volume={54},
8  number={7},
9  doi={10.1145/3461835},
10 art_number={143},
11 note={cited By 0},
12 url={https://www.scopus.com/inward/record.uri?eid=2-s2
       .0-8511544568&doi=10.1145%2f3461835&partnerID=40&md5=
       b500d2a13510d0d236a64c853d25f379},
13 affiliation={Federal University of Para, Augusto Correa St., 01,
        Belem, Para, 66075-110, Brazil},
14 abstract={Music Information Research (MIR) comprises all the
       research topics involved in modeling and understanding music.
        Visualizations are frequently adopted to convey better
       understandings about music pieces, and the association of
       music with visual elements has been practiced historically
       and extensively. We investigated papers related to music
       visualization and organized the proposals into categories
```

```
    according to their most prominent aspects: their input
    features, the aspects visualized, the InfoVis technique(s)
    used, if interaction was provided, and users' evaluations.
    The MIR and the InfoVis community can benefit by identifying
    trends and possible new research directions within the music
    visualization topic. 2021 ACM.},
author_keywords={human-computer interaction; information
    visualization; music information retrieval; Music
    visualization},
document_type={Article},
source={Scopus},
}
```

Nosotros nos centraremos en el desarrollo de un sistema de recuperación de información básico capaz de trabajar con estos datos.

En PRADO se puede encontrar tres ficheros .csv (con los campos separados por comas), donde cada uno contiene información sobre 2000 artículos científicos relacionados con una determinada temática. Podéis descargarlos para empezar a familiarizaros con los mismos.

En cualquier caso, podremos bajarnos distintas ficheros con datos haciendo consultas sobre Scopus. Por ejemplo, si consultamos documentos que hablen sobre "Natural Language Processing.[en] el título, abstract o keywords encontramos que hay un total de 78437 documentos. Scopus no nos va a permitir descargarnos todos los documentos, pero si podremos descargarnos la información que necesitamos sobre los 2000 primeros documentos en el orden.

Para ello, marcamos la casilla que seleccionaría todos los documentos (ALL) habitándonos la posibilidad de descarga de los mismos a través de la opción de exportación (CSV export). Al desplegarla podremos indicarle que también descargue el abstract y keywords y cuando lo tenemos ya todo procedemos a la descarga propiamente dicha (export), donde en la ventana emergente le indicaremos que se descargue la información completa sobre los primeros 2000 documentos. Los encontraremos en nuestro directorio de descarga con el nombre `scopus.csv`.

Para la práctica deberemos descargarnos al menos 20000 artículos (esto implica realizar la descarga de los documentos relevantes a unas 10 consultas).

Para poder trabajar con los mismos deberemos ser capaz de extraer los atribu-

tos del fichero .csv. Con este fin se recomienda el uso de una librería específica para la lectura de este tipo de información como puede ser `openCSV` `https://mkyong.com/java/how-to-read-and-parse-csv-file-in-java/` (o cualquier otra que se conozca)

3. Diseñando nuestro sistema

Una vez que conocemos los datos de nuestra práctica, podremos imaginar qué tipos de consultas se podrían realizar por un usuario así como la/las respuesta que daría el sistema, en la cual se devuelven los elementos ordenados por relevancia, facilitando las labores del usuario. Lucene permite hacer consultas por campos, por lo que será necesario identificar los mismos. Los campos concretos dependerá de la aplicación concreta sobre la que estemos trabajando, pero como hemos visto si es necesario un mismo campo podrá utilizarse para dos funciones distintas, por ejemplo como texto sin tokenizar y texto tokenizado.

En cualquier caso, en nuestra aplicación deberemos identificar al menos los siguientes tipos de campos sobre los documentos de entrada:

- StringField Texto simple que se considera literalmente (no se tokeniza), útil para la búsqueda por facetas, filtrado de consultas y también para la presentación de resultados en la interfaz de búsqueda, por ejemplo ID, tags, direcciones webs, nombres de fichero, etc.

- TextField: Secuencia de términos que es procesada para la indexación, esto es, convertida a minúscula, tokenizada, estemizada, etc. Como podría ser el título, resumen, etc de un artículo científico o de la consulta de Stack Overflow.

- Numérico, datos que se expresan mediante este tipo de información, bien sean enteros o reales.

- Facetas (Categorías) que permiten una agrupación lógica de los documentos con la misma faceta, como por ejemplo la revista donde se publicó el trabajo, la fecha de publicación, o el país de origen de los autores.

Además de una consulta por texto libre, en la aplicación se deberá poder realizar como mínimo una consulta booleana que involucre a los operadores lógicos OR, AND o NOT en la misma. Además deberemos proporcionar algún tipo de consulta avanzada como por ejemplo las consultas por proximidad, así como permitir presentar la información utilizando distintos criterios de ordenación (esto es, además de presentar los elementos ordenados por relevancia, debemos de poder presentarlo utilizando un orden distinto).

3.1. Búsqueda por Facetas

Una búsqueda por facetas nos permite acceder a la información refinando la búsqueda de acuerdo a una clasificación por categorías, filtrando los datos teniendo en cuenta las categorías a las que pertenecen. Para ello, es necesario que cada documento pueda ser clasificado a lo largo de múltiples dimensiones (llamadas facetas) como por ejemplo el autor, el idioma o en un sitio de comercio electrónica cada una de las posibles categorías bajo las que podemos clasificar un producto (marca, modelo, características, etc.).

Un atractivo de la mezcla de la búsqueda con el uso de la navegación por facetas es que, ante una consulta, podemos mostrar el número de elementos recuperados en cada una de las categorías. Así, por ejemplo, podemos saber cuantos trabajos, de entre los relevantes a la consulta, han sido publicados en el año `2015` o el `2016`, o cuántos de ellos han sido escritos por un determinado autor. Además, cuando el usuario selecciona una de ellas podemos restringir la búsqueda (drill down) entre los documentos que pertenecen a dicha categoría. Esta información hace fácil la búsqueda de los elementos de interés, ya que el usuario puede navegar fácilmente por los resultados, facilitando las siguientes interacciones con el sistema para refinar la búsqueda.

Esta peculiaridad ha hecho que la búsqueda por facetas sea muy común en sitios de comercio electrónico, como por ejemplo Amazon. En la Figura 1 podemos ver cómo ante la consulta “Java” encontramos un total de 22075 libros en el portal de ventas Amazon. A la izquierda de la misma encontramos un frame en el que se permite mostrar los resultados por categorías (aunque Amazon, por motivos internos, ha decidido no mostrar cuántos libros hay en cada una de las categorías).

Entre las categorías que considera Amazon encontramos el tipo de libro, lenguaje, autores, formato, etc.

Figura 1: Búsqueda de libros en Amazon, consulta: “Java”. Se encuentran un total de 22.075 libros.

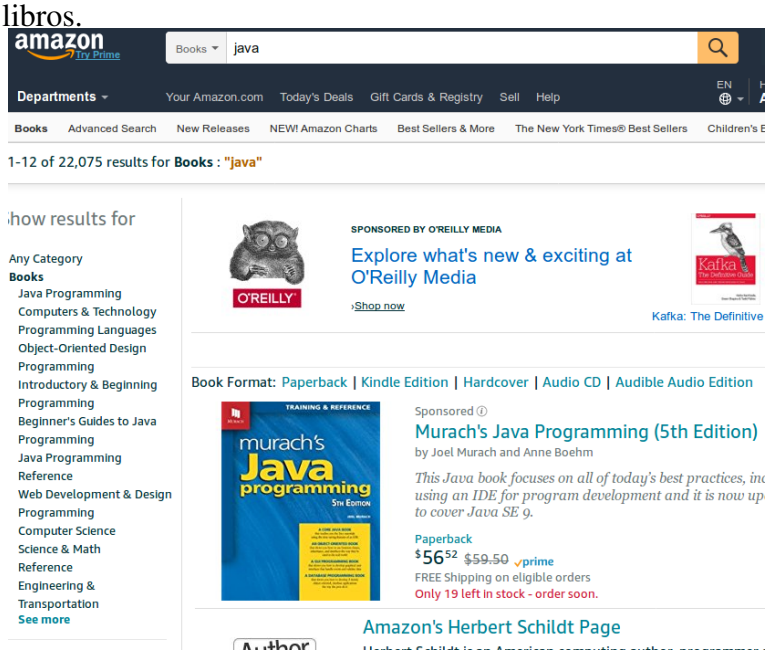

Así, podemos centrar la búsqueda dentro de la categoría Computer-Science (imagen a la izquierda de la Figura 2), encontrando un total de 1255 libros y dentro de ella, podemos de nuevo restringirnos a los libros que han sido editados en Alemán (imagen a la derecha de la Figura 2), encontrando un total de 107 libros.

3.2. Uso de Facetas

Nuestro sistema final deberá realizar la búsqueda por facetas. Para ello en esta etapa se deberá identificar los campos por los que podrá clasificar los documentos. Así, como resultado de la búsqueda, podremos tener los resultados agrupados por categorías, permitiendo al usuario bucear por ellas en busca de la información de su interés. La documentación más extensa sobre esta parte la veremos posteriormente.

Figura 2: Consulta: “Java”, restringimos la búsqueda a los libros que se encuadran dentro de la categoría computer-science (izq.) o computer-science ->Alemán (dcha.) Se encuentran un total de 22.075 libros.

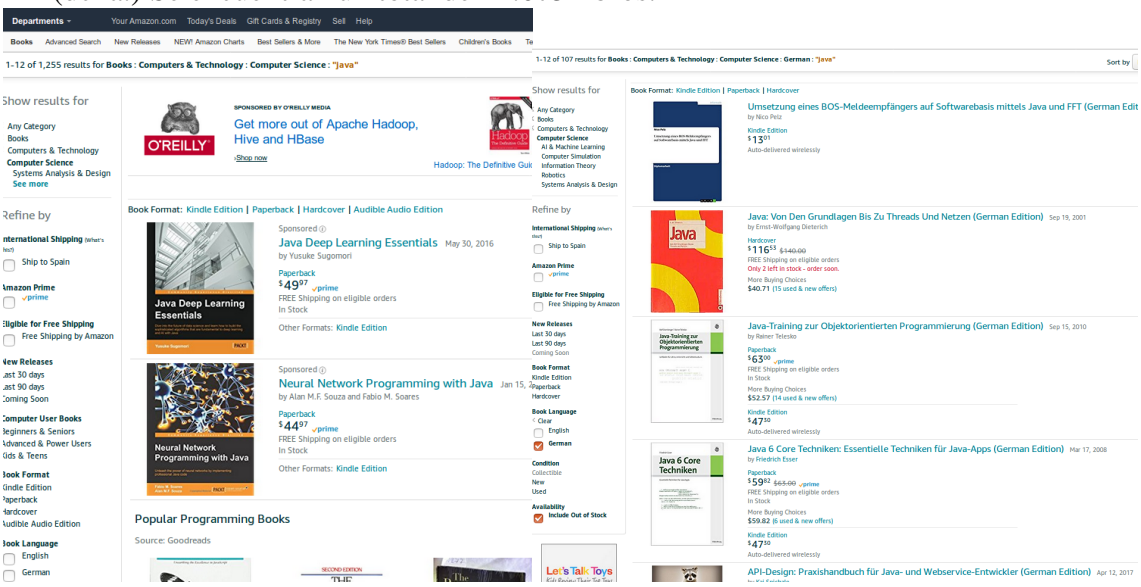

4. Indexación de documentos

Indexar es una de las principales tareas que podemos encontrar en Lucene. La clase que se encarga de la indexación de documentos es IndexWriter. Esta clase se encuentra en `lucene-core` y permite añadir, borrar y actualizar documentos Lucene. Un documento Lucene esta compuesto por un conjunto de campos: par nombre del campo (string)- contenido del campo (string), como por ejemplo (“autor”, “Miguel de Cervantes”) o (“Título”, “Don Quijote de la Mancha”) o ‘(“Cuerpo”,“En un lugar de la Mancha de cuyo....”). Cada uno de estos campos será indexado como parte de un documento, después de pasar por un Analyzer. En el Cuadro 1 podemos ver resumido el conjunto de clases que son usadas frecuentemente en la indexación.

El IndexWriter `http://lucene.apache.org/core/7_1_0/core/org/apache/lucene/index/IndexWriter.html` toma como entrada dos argumentos:

- Directory: Representa el lugar donde se almacenará el índice `http://lucene.apache.org/core/7_1_0/core/org/apache/lucene/`

Cuadro 1: Clases involucradas en la indexación

Clase	Descripción
IndexWriter	Clase esencial que crea/modifica un índice.
Directory	Representa la ubicación del índice.
Analyzer	Es responsable de analizar un texto y obtener los tokens de indexación.
Document	Representa un documento Lucene, esto es, un conjunto de campos (fields) asociados al documento.
Field	La unidad más básica, representa un par clave-valor, donde la clave es el nombre que identifica al campo y el valor es el contenido del documento a indexar.

`store/Directory.html`. Podemos encontrar distintas implementaciones, pero para un desarrollo rápido de un prototipo podemos considerar RAMDirectory (el índice se almacena en memoria) o FSDirectory (el índice se almacena en el sistema de ficheros)

- IndexWriterConfig: Almacena la configuración utilizada `http://lucene.apache.org/core/7_1_0/core/org/apache/lucene/index/IndexWriterConfig.html`

Aunque se recomienda mirar la documentación de las distintas clases, ilustraremos su uso mediante el siguiente ejemplo,

```
1  FSDirectory dir = FSDirectory.open( Paths.get(INDEX_DIR) );
2  IndexWriterConfig config = new IndexWriterConfig( analyzer );
3  config.setOpenMode(IndexWriterConfig.OpenMode.CREATE).set;
4    // config.setSimilarity(new LMDirichletSimilarity ());
5
6
7   //Crea un nuevo indice
8  IndexWriter writer = new IndexWriter(dir, config);
9
10 List<string> listaFicheros = .....
11
12 for (String nombre: listaFicheros)
13        Document doc = ObtenerDocDesdeFichero(nombre);
14        writer.addDocument(doc);
15
```

```
16  writer.commit();
17  // Ejecuta todos los cambios pendientes en el indice
18  writer.close();
```

Las líneas 1 a 4 son las encargadas de crear las estructuras necesarias para el índice. En concreto el índice se almacenará en disco en la dirección dada por el path. La línea 2 declara un IndexWriterConfig config con el analizador que se utilizará para todos los campos (si no se indica, utilizará por defecto el standardAnalyzer). Para ello, debemos de seleccionar, de entre los tipos que tiene Lucene implementados, el que se considere adecuado para nuestra aplicación. Este es un criterio importante para poder alcanzar los resultados óptimos en la búsqueda. Puede que sea necesario el utilizar un analizador distinto para cada uno de los posibles campos a indexar, en cuyo caso utilizaremos un PerFieldAnalyzerWrapper (ver siguiente sección).

La línea 3 se indica que el índice se abre en modo CREATE (crea un nuevo índice o sobreescribe uno ya existente), otras posibilidades son APPEND (añade documentos a un índice existente) o CREATE_OR_APPEND (si el índice existe añade documentos, si no lo crea para permitir la adición de nuevos documentos. Es posible modificar la configuración del índice considerando múltiples setter. Por ejemplo, podremos indicar la función de similitud que se utiliza, por defecto es BM25 (ver línea 4) o criterios para la mezcla de índices, etc.

Una vez definida la configuración tenemos el IndexWriter listo para añadir nuevos documentos. Los cambios se realizarán en memoria y periódicamente se volcarán al Directory, que cuando sea necesario realizará la mezcla de distintos segmentos.

Una vez añadidos los documentos, debemos asegurarnos de llamar a commit() para realizar todos los cambios pendientes, línea 16. Finalmente podremos cerrar el índice mediante el comando close (línea 18).

4.1. Selección del analizador

El proceso de análisis nos permite identificar qué elementos (términos) serán utilizados en la búsqueda y cuales no (por ejemplo mediante el uso de palabras vacías)

Las operaciones que ejecuta un analizador incluyen: extracción de tokens, supresión de signos de puntuación, acentos o palabras comunes, conversión a minúsculas (normalización), stemización. Para ello, debemos de seleccionar de entre los tipos que tiene Lucene implementados, el que se considere adecuado para nuestra aplicación, justificando nuestra decisión. Este es un criterio importante para poder alcanzar los resultados óptimos en la búsqueda.

En esta práctica será necesario utilizar un analizador distinto al por defecto para algunos de los posibles campos a indexar, para ello podemos utilizar un `PerFieldAnalyzerWrapper` como indica el siguiente ejemplo.

```
1 // map field-name to analyzer
2 Map<String, Analyzer> analyzerPerField = new HashMap<String,
    Analyzer>();
3 analyzerPerField.put("uncampo", new StandardAnalyzer());
4 analyzerPerField.put("otrocampo", new EnglishAnalyzer());
5
6 // create a per-field analyzer wrapper using the Whitespace as
    .. default analyzer ;)
7 PerFieldAnalyzerWrapper analyzer = new PerFieldAnalyzerWrapper(
    new WhitespaceAnalyzer(), analyzerPerField);
```

5. Creación de un Document Lucene

Hemos visto que para indexar la información es necesario la creación de un documento, `Document`, Lucene `http://lucene.apache.org/core/7_1_0/core/org/apache/lucene/document/Document.html`. Un Document es la unidad de indexación y búsqueda. Está compuesto por un conjunto de campos Fields, cada uno con su nombre y su valor textual. Un field puede ser el nombre de un producto, su descripción, su ID, etc. Veremos brevemente cómo se gestionan los Fields ya que es la estructura básica de la que está compuesta un Docuement. Información sobre los Fields la podemos encontrar en `http://lucene.apache.org/core/7_1_0/core/org/apache/lucene/document/Field.html`.

Un Field tiene tres componentes, el nombre, el tipo y el valor. En nombre hace referencia la nombre del campo (equivaldría al nombre de una columna en una ta-

bla). El valor hacer referencia al contenido del campo (la celda de la tabla) y puede ser texto (String, Reader o un TokenStream ya analizado), binario o numérico. El tipo determina como el campo es tratado, por ejemplo indicar si se almacena (store) en el índice, lo que permitirá devolver la información asociada en tiempo de consulta, o si se tokeniza.

Para simplificar un poco la tarea, Lucene dispone de tipos predefinidos

- TextField: Reader o String indexado y tokenizado, sin term-vector[1].
- StringField: Un campo String que se indexa como un único token. Por ejemplo, se puede utilizar para ID de un producto, el path donde se encuentra el archivo, etc. Si queremos que la salida de una búsqueda pueda ser ordenada según este campo, se tiene que añadir otro campo del tipo SortedDocValuesField.
- IntPoint: Entero indexado para búsquedas exactas o por rango. Si queremos devolverlo en consultas, lo debemos de añadir como StoredField
- LongPoint: Long indexado para búsquedas exactas o por rango. Si queremos devolverlo en consultas, lo debemos de añadir como StoredField
- FloatPoint: float indexado para búsquedas exactas o por rango. Si queremos devolverlo en consultas, lo debemos de añadir como StoredField
- DoublePoint: double indexado para búsquedas exactas o por rango. Si queremos devolverlo en consultas, lo debemos de añadir como StoredField.
- SortedDocValuesField: byte[] indexados con el objetivo de permitir la ordenación o el uso de facetas por el campo
- SortedSetDocValuesField: Permite añadir un conjunto de valores, SortedSet, al campo para su uso en facetas, agrupaciones o joinings.

[1]En Lucene, un term-vector implica que para cada término conocemos: el id del documento, el nombre del campo, el texto en sí, la frecuencia, la posición y los offsets. Esta información podemos hacer cosas interesantes en la búsqueda como conocer dónde emparejan los teŕminos de la consulta (por ejemplo para hacer un highlinghting)

- NumericDocValuesField: Field que almacena a valor long por documento con el fin de utilizarlo para ordenación, facetas o el propio cálculo de scoeres.
- SortedNumericDocValuedFiled: Añade un conjunto de valores numéricos, SortedSet, al campo
- StoredField: Valores almacenados que solo se utilizan para ser devueltos en las búsquedas.

Los distintos campos de un documento se añaden con el método add.

```
1  Document doc = new Document();
2
3  doc.add(new StringField("isbn", "978-0071809252", Field.Store.
       YES));
4  doc.add(new TextField("titulo", "Java: A Beginner's Guide,
       Sixth Edition",Field.Store.YES)); // por defecto no se
       almacena
5  doc.add(new TextField("contenido", "Fully updated for Java
       Platform, Standard Edition 8 (Java SE 8), Java ......"));
6  doc.add(new IntPoint("size", 148));
7  doc.add(new StoredField("size",148));
8  doc.add(new SortedSetDocValuesField("format", new BytesRef("
       paperback")));
9  doc.add(new SortedSetDocValuesField("format", new BytesRef("
       kindle")));
10
11 Date date = new SimpleDateFormat("yyyy-MM-dd'T'HH:mm:ss'Z'").
       parse(...);
12 doc.add(new LongPoint("Date", date.getTime()));
```

Como podemos imaginar, para cada tipo tenemos un comportamiento especifico, aunque nosotros podremos crear nuestro propio tipo de campo.

```
1
2  FieldType authorType = new FieldType();
3  authorType.setIndexOptions(IndexOptions.DOCS_AND_FREQS);
4  //authorType.setIndexOptions(IndexOptions.
       DOCS_AND_FREQS_AND_POSITIONS_AND_OFFSETS);
```

```
5   authorType.setStored(true);
6   authorType.setOmitNorms(true);
7   authorType.setTokenized(false);
8   authorType.setStoreTermVectors(true);
9
10  doc.add(new Field("author", "Arnaud Cogoluegnes", authorType))
        ;
11  doc.add(new Field("author", "Thierry Templier", authorType));
12  doc.add(new Field("author", "Gary Gregory", authorType));
```

6. Ejercicios

1. Basándonos en el código anterior, implementar un pequeño programa que nos permite añadir varios documentos a un índice Lucene, podemos seguir el siguiente esquema.

```
1
2   import org.apache.lucene.analysis.Analyzer;
3   import org.apache.lucene.analysis.standard.
        StandardAnalyzer;
4   .....
5
6   public class IndiceSimple {
7
8     String indexPath = "./index";
9     String docPath = "./DataSet";
10
11    boolean create = true;
12
13    private IndexWriter writer;
14
15  public static void main(String[] args) {
16      // Analizador a utilizar
17      Analyzer analyzer = new StandardAnalyzer();
18      // Medida de Similitud (modelo de recuperacion) por
            defecto BM25
19      Similarity similarity = new ClassicSimilarity();
20      // Llamados al constructor con los parametros
```

```
21        IndiceSimple baseline = new IndiceSimple( ... );
22
23        // Creamos el indice
24        baseline.configurarIndice(analyzer, similarity);
25        // Insertar los documentos
26        baseline.indexarDocumentos();
27        // Cerramos el indice
28        baseline.close();
29
30
31      }
32
33    public void configurarIndice(Analyzer analyzer, Similarity
          similarity) throws IOException {
34
35
36          IndexWriterConfig iwc = new IndexWriterConfig(
                analyzer);
37          iwc.setSimilarity(similarity);
38          // Crear un nuevo indice cada vez que se ejecute
39          iwc.setOpenMode(IndexWriterConfig.OpenMode.CREATE);
40          // Para insertar documentos a un indice existente
41          // iwc.setOpenMode(IndexWriterConfig.OpenMode.
                CREATE_OR_APPEND);
42
43
44
45          // Localizacion del indice
46          Directory dir= FSDirectory.open(Paths.get(indexPath)
                );
47
48          // Creamos el indice
49          writer = new IndexWriter(dir, iwc);
50
51
52      }
53
54    public void indexarDocumentos() {
55
```

```
56      // Para cada uno de los documentos  a insertar
57      for (elementos d : docPath) {
58
59        //leemos el documento sobre un string
60        String cadena = leerDocumento( d );
61          // creamos el documento Lucene
62          Document doc = new Document();
63
64          //parseamos la cadena (si es necesario)
65          Integer start,end; // Posiciones inicio,fin
66
67          // Obtener campo Entero de cadena
68          Integer start = ... // Posicion de inicio del campo;
69          Integer end =  ... // Posicion  fin del campo;
70          String aux = cadena.substring(start, end);
71          Integer valor = Integer.decode(aux);
72
73          // Almacenamos en el campo en el documento Lucene
74          doc.add(new IntPoint("ID", valor));
75          doc.add(new StoredField("ID", valor));
76
77           // Obtener campo texto de cadena
78          start = ... // Posicion de inicio del campo;
79          end =  ... // Posicion  fin del campo;
80          String cuerpo = cadena.substring(start,end);
81          // Almacenamos en el campo en el documento Lucene
82          doc.add(new TextField("Body", cuerpo, Field.Store.
                YES));
83
84          //Obtenemos los siguientes campos
85
86          // ......
87
88          // Insertamos el documento Lucene en el indice
89          writer.addDocument(doc);
90          // Si lo que queremos es actualizar el documento
91          // writer.updateDocument(new Term("ID", valor.
                toString()), doc);
92        }
```

```
93
94      }
95
96
97      public void close() {
98        try {
99          writer.commit();
100         writer.close();
101       } catch (IOException e) {
102         System.out.println("Error closing the index.");
103       }
104     }
105
106   }
```

2. Utilizar Luke para ver el índice y realizar distintas consultas sobre el mismo.